

Méthodes alternatives de la régression

Régression sur composantes principales - Régression Ridge

Mourad Bahaddou Hatim Rakkal

Filière : Data Science



Institut National de Statistique et d'Economie Appliquée

- 1 Introduction
- 2 Limites de la régression
- 3 Régression sur composantes principales (RCP)
- 4 Régression Ridge
- 5 Conclusion

- 1 Introduction
- 2 Limites de la régression
- 3 Régression sur composantes principales (RCP)
- 4 Régression Ridge
- 5 Conclusion

- Soit le modèle de régression suivant :

$$Y = a_0 \mathbb{1}_n + a_1 x_1 + \dots + a_d x_d + \varepsilon$$

Avec $d \in \mathbb{N}^*$, $x_1, \dots, x_d \in \mathbb{R}^n$ sont les variables explicatives, $Y \in \mathbb{R}^n$ est la variable à expliquer et $\varepsilon \in \mathbb{R}^n$ est l'erreur aléatoire.

On pose : $X = \begin{bmatrix} x_1 & \dots & x_d \end{bmatrix} \in \mathbb{R}^{n \times d}$ la matrice de données.

Hypothèses standards :

- $\mathbb{E}(\varepsilon) = 0_n$ ($\mathbb{E}(\varepsilon_i) = 0$, $i = 1, \dots, n$)
- $\mathbb{V}(\varepsilon) = \sigma^2 I_n$
- Les erreurs ε_i sont non corrélées / indépendantes.
- L'erreur ε et la variable explicative X sont indépendantes.
- $n \geq d$ et $X^\top X \in \mathbb{R}^{d \times d}$ est inversible.
- $\forall 1 \leq i \leq n; \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$

- 1 Introduction
- 2 Limites de la régression
- 3 Régression sur composantes principales (RCP)
- 4 Régression Ridge
- 5 Conclusion

- **Dans ses hypothèses :**

Si ces hypothèses ne sont pas vérifiées, les modèles de régression peuvent entraîner des résultats biaisés ou invalides.

- **Multicolinéarité :**

La multicolinéarité augmente la **variance des coefficients estimés** et il faut la gérer.

- **Overfitting :**

Le modèle devient trop complexe et apprend le bruit ou les détails spécifiques des données d'entraînement au lieu de généraliser à de nouvelles données.

- **Les méthodes alternatives** permettent de gérer ces problèmes. (gérer la multicolinéarité, réduire le surajustement, et sélectionner les variables pertinentes en ajoutant des pénalités aux coefficients du modèle...) .

- 1 Introduction
- 2 Limites de la régression
- 3 Régression sur composantes principales (RCP)
- 4 Régression Ridge
- 5 Conclusion

- L'idée est de réduire le nombre de variables explicatives x_i ($1 \leq i \leq d$) par l'ACP, puis faire la régression sur les nouvelles variables. Avec les liens qui existe entre eux, on peut trouver une estimation des a_i ($0 \leq i \leq d$). Cette méthode est appelée Régression sur composantes principales **RCP**.
- **L'RCP** diminue indirectement l'impact de la multicolinéarité.

- Avant de commencer, il faut toujours **centrer et réduire la matrice de données**.
- La moyenne de la matrice de données est : $\bar{X} = [\bar{x}_1 \quad \dots \quad \bar{x}_d]$
- Pour $1 \leq j \leq d$, L'écart-types de x_j est donné par :

$$s_j = \left(\frac{1}{n-1} (x_j - \bar{x}_j)^\top (x_j - \bar{x}_j) \right)^{1/2}$$

On note $S = \text{diag}(s_1, \dots, s_d)$.

- La matrice des données centrée réduite est donnée donc par :

$$X_{cr} = \begin{bmatrix} \frac{1}{s_1} (x_1 - \bar{x}_1) & \dots & \frac{1}{s_d} (x_d - \bar{x}_d) \end{bmatrix} = (X - \bar{X})S^{-1}$$

- On a $\hat{\Sigma} = \frac{1}{n-1} X_{cr}^\top X_{cr}$ est **un estimateur sans biais** de la variance de X_{cr} .
- Pour trouver **les composantes principales**, on diagonalise $\hat{\Sigma}$. On écrit:

$$\hat{\Sigma} = P \Lambda P^\top$$

avec $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$ où les λ_i sont les valeurs propres de $\hat{\Sigma}$ telles que $\lambda_1 > \dots > \lambda_d$.

$P = [p_1 \dots p_d] \in \mathbb{R}^{d \times d}$ la matrice orthogonale qui contient les composantes principales.

- On choisit les k premières composantes qui expliquent une grande pourcentage des variables initiales, en calculant **la variance retenue par ces composantes**, par exemple on prend $1 \leq k \leq d$ telle que :

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^d \lambda_i} > 95\%$$

- Les nouvelles variables explicatives w_i avec $1 \leq i \leq k$ sont donner par **les projections des variables explicatives initiales sur p_i** .
- On a :

$$\forall 1 \leq i \leq k \quad ; \quad w_i = X_{cr} p_i \in \mathbb{R}^n$$

- On pose $W_k = [w_1 \quad \dots \quad w_k] \in \mathbb{R}^{n \times k}$, $P_k = [p_1 \quad \dots \quad p_k] \in \mathbb{R}^{d \times k}$.
- On a :

$$W_k = X_{cr} P_k$$

- Le nouveau modèle de régression est :

$$Y = \beta_0 \mathbf{1}_n + \beta_1 w_1 + \dots + \beta_k w_k + \tilde{\varepsilon}$$

$$= \beta_0 \mathbf{1}_n + W_k \beta_{1,\dots,k} + \tilde{\varepsilon}$$

avec $\beta_{1,\dots,k} = (\beta_1, \dots, \beta_k)^\top \in \mathbb{R}^k$.

- Les estimateurs des MCO de $\beta_{1,\dots,k}$ et β_0 sont :

$$\hat{\beta}_{1,\dots,k} = (W_k^\top W_k)^{-1} W_k^\top Y$$

$$\hat{\beta}_0 \mathbf{1}_n = \bar{Y} - \bar{W}_k \hat{\beta}_{1,\dots,k}$$

- Les valeurs prédites sont données par :

$$\hat{Y} = \hat{\beta}_0 \mathbb{1}_n + W_k \hat{\beta}_{1,\dots,k}$$

- En utilisant que $W_k = X_{cr} P_k$, On trouve $\hat{Y}$ en fonction de $x_1, \dots, x_d$:

$$\hat{Y} = \hat{\beta}_0 \mathbb{1}_n - \bar{X} S^{-1} P_k \hat{\beta}_{1,\dots,k} + X S^{-1} P_k \hat{\beta}_{1,\dots,k}$$

- Donc, des estimations de a_0 et $a_{1,\dots,d} = (a_1, \dots, a_d)^\top \in \mathbb{R}^d$ sont données par :

$$\hat{a}_0 \mathbb{1}_n = \hat{\beta}_0 \mathbb{1}_n - \bar{X} S^{-1} P_k \hat{\beta}_{1,\dots,k}$$

$$\hat{a}_{1,\dots,d} = S^{-1} P_k \hat{\beta}_{1,\dots,k}$$

- 1 Introduction
- 2 Limites de la régression
- 3 Régression sur composantes principales (RCP)
- 4 Régression Ridge**
- 5 Conclusion

Régression Ridge

Principe

- La régression Ridge a été introduite par **Hoerl** et **Kennard** en 1970 pour résoudre le problème d'inversibilité de $X^T X$. Dans les modèles de régression linéaire, cette méthode est particulièrement utile dans les situations où $n < d$ ou en présence de multicollinéarité (fortes corrélations entre les $x_i \forall i$). La méthode Ridge modifie la fonction coût en ajoutant une pénalité basée sur la norme $\| \cdot \|_2$ des coefficients du modèle. Le problème d'optimisation consiste alors à résoudre :

$$\min_{\beta \in \mathbb{R}^d} (\|Y - X\beta\|_2^2 + \lambda \|\beta\|_2^2)$$

Avec λ : paramètre de régularisation (il contrôle l'intensité de pénalisation) .

- La solution est donnée par :

$$\hat{\beta} = (X^{\top} X + \lambda I_{d+1})^{-1} X^{\top} Y$$

- Lorsque $\lambda = 0$, on a :

$$\hat{\beta} = \hat{\beta}_{\text{MCO}} = (X^{\top} X)^{-1} X^{\top} Y$$

- lorsque $\lambda \rightarrow +\infty$: $\hat{\beta} \approx \frac{1}{\lambda} X^{\top} Y \xrightarrow{\lambda \rightarrow +\infty} 0$

- Après calcul, on trouve :

$$\mathbb{E}(\hat{\beta}) = \beta I_{d+1} - \lambda (X^{\top} X + \lambda I_{d+1})^{-1} \beta$$

$$\mathbb{V}(\hat{\beta}) = \sigma^2 (X^{\top} X + \lambda I_{d+1})^{-1} X^{\top} X (X^{\top} X + \lambda I_{d+1})^{-1}$$

Régression Ridge

Choix du paramètre de régularisation : Méthode analytique

- **Méthode analytique (Hoerl et Kennard) :**

Le paramètre de régularisation λ peut être estimé par :

$$\lambda = \frac{d \cdot \text{CMR}}{\|\hat{\beta}_{\text{MCO}}\|_2^2}$$

$$\text{Avec : } \text{CMR} = \frac{\text{SCR}}{n - d} = \frac{1}{n - d} \|\hat{Y} - Y\|_2^2$$

Régression Ridge

Choix du paramètre de régularisation : Méthode basée sur les VIF

- **Méthode basée sur les VIF :**

Pour chaque variable x_j ($1 \leq j \leq d$) , le VIF est défini par :

$$\text{VIF}(x_j) = \frac{1}{1 - R_j^2}$$

Avec R_j^2 le coefficient de détermination de la régression de x_j sur les autres variables.

On a :

$$(X^T X + \lambda I_{d+1})^{-1} = \frac{1}{n} R_\lambda^{-1}$$

La variance des coefficients s'exprime alors comme :

$$\mathbb{V}(\hat{\beta}_j) = \frac{\sigma^2}{n} (R_\lambda^{-1})_{jj}$$

Régression Ridge

Choix de paramètre de régularisation : Méthode basée sur les VIF

- **Critère de selection de λ :**

On choisi λ tel que $VIF < 10$ pour atténuer les effets de multicollinéarité.

- 1 Introduction
- 2 Limites de la régression
- 3 Régression sur composantes principales (RCP)
- 4 Régression Ridge
- 5 Conclusion

- La Régression sur Composantes Principales (RCP) et la Régression Ridge offrent des solutions robustes aux problèmes de multicolinéarité et de singularité de $X^T X$. La RCP réduit la dimension via l'ACP, tandis que Ridge stabilise les coefficients par une pénalisation $\|\cdot\|_2$. Ensemble, elles permettent des modèles fiables même lorsque les données sont dégénérées ou de haute dimension.